DWM Report

Gabriele Armani Nicolò Scantamburlo

June 2025

1 Introduzione

Il presente lavoro è stato svolto per il corso di **Data and Web Mining** e ha l'obiettivo di esplorare un problema di classificazione supervisionata applicando diverse tecniche di machine learning. Il dataset utilizzato proviene da una competizione Kaggle dal titolo **"Child Mind Institute — Problematic Internet Use"**, il cui scopo è predire il livello di utilizzo problematico di Internet da parte di bambini e adolescenti in base alla loro attività fisica e altri indicatori relativi al benessere fisico e psicologico.

La variabile target è il **Severity Impairment Index (sii)**, un indice compreso tra 0 e 3, dove 0 indica nessun problema e 3 indica gravi problemi. L'accurata previsione di tale indice può rappresentare un primo passo nell'identificazione precoce di comportamenti digitali potenzialmente dannosi.

Il progetto si articola nelle seguenti fasi:

- preparazione e pulizia dei dati,
- confronto tra modelli predittivi,
- valutazione delle prestazioni,
- analisi dell'importanza delle feature,

2 Preparazione e pulizia dei dati

Il dataset di training è stato inizialmente ispezionato per comprenderne la struttura e la presenza di valori mancanti. La variabile target **sii** presenta alcuni valori nulli (**NaN**), che non possono essere utilizzati negli algoritmi di apprendimento supervisionato. Tali istanze sono quindi state rimosse dal dataset.

In seguito, sono state escluse dal training tutte le colonne il cui nome contiene la stringa **PCIAT** (**Parent-Child Internet Addiction Test**). Infatti, come specificato nel data dictionary, il valore della variabile target **sii** è derivato direttamente da **PCIAT_Total**. Queste colonne sono state escluse in quanto altamente correlate con la variabile target.

Inoltre, è stata rimossa la colonna contenente l'identificativo univoco assegnato a ciascun partecipante, in quanto non informativa ai fini della predizione.

Successivamente, sono state effettuate ulteriori operazioni di pulizia e trasformazione dei dati. Le righe contenenti valori uguali a zero nella variabile **Physical-Weight** sono state rimosse, poiché non sono valori plausibili.

Le colonne **Physical-BMI** e **BIA-BIA_BMI**, contenenti due stime simili dell'indice di massa corporea, sono risultate fortemente correlate. È stata creata una nuova variabile ottenuta come media aritmetica tra le due.

Le variabili categoriali stagionali **Season** sono state trasformate mediante **one-hot encoding**.

Infine, sono state eliminate le colonne con oltre il 50% di valori mancanti e che presentavano una correlazione inferiore al 10% con la variabile target.

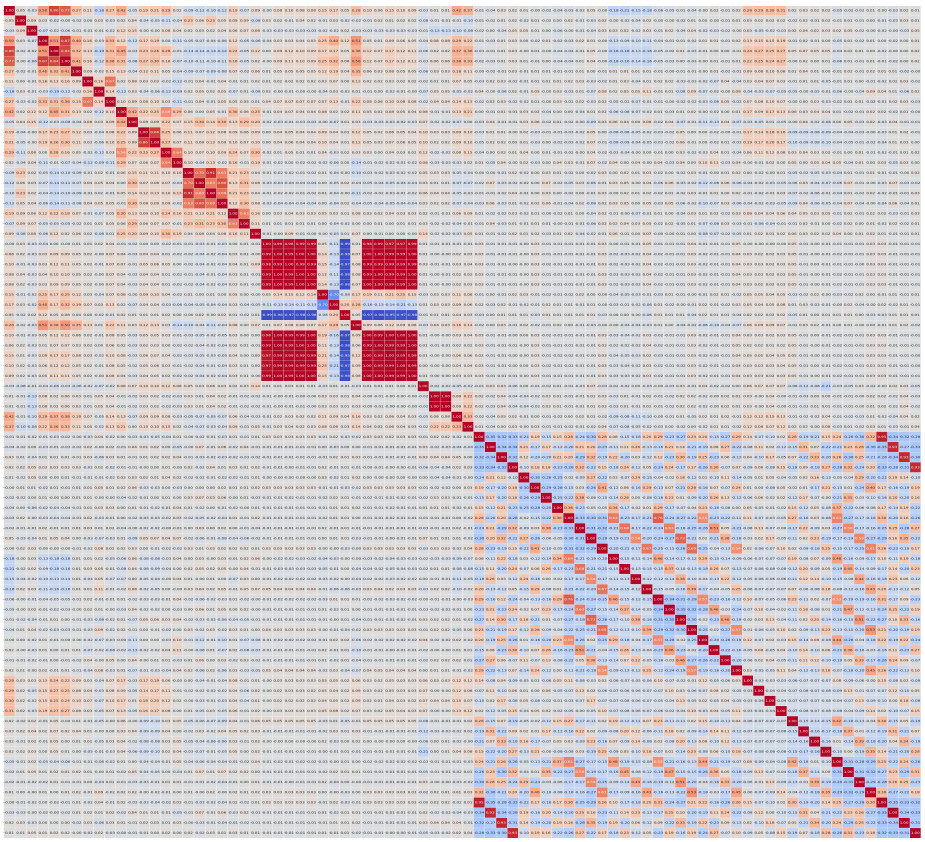


Figure 1: Mappa di correlazione tra le variabili del dataset. Le celle in **rosso** indicano una correlazione positiva forte, quelle in **blu** una correlazione negativa, mentre i colori più neutri rappresentano assenza o bassa correlazione.

3 Confronto tra modelli predittivi

Dopo la preparazione del dataset, si è proceduto con l'addestramento e la valutazione di quattro modelli supervisionati: **Decision Tree**, **Random Forest**, **XGBoost** e **LightGBM**.

Per garantire la riproducibilità e l'affidabilità dei risultati, il dataset è stato suddiviso in **80% dati di training** e **20% dati di test**. Inoltre, durante il training e la selezione dei parametri, è stata utilizzata una cross-validation con **20 fold**. Prima dell'addestramento, è stata analizzata la distribuzione della variabile target **sii**, i cui valori sono sbilanciati, con una predominanza della classe 0:

```
sii
0.0    58.1\%
1.0    26.7\%
2.0    13.9\%
3.0     1.3\%
```

Questo squilibrio comporta che un classificatore banale che predice sempre la classe più frequente otterrebbe già un'accuratezza del 58%, fornendo quindi una soglia minima da superare.

Strategia comune di addestramento

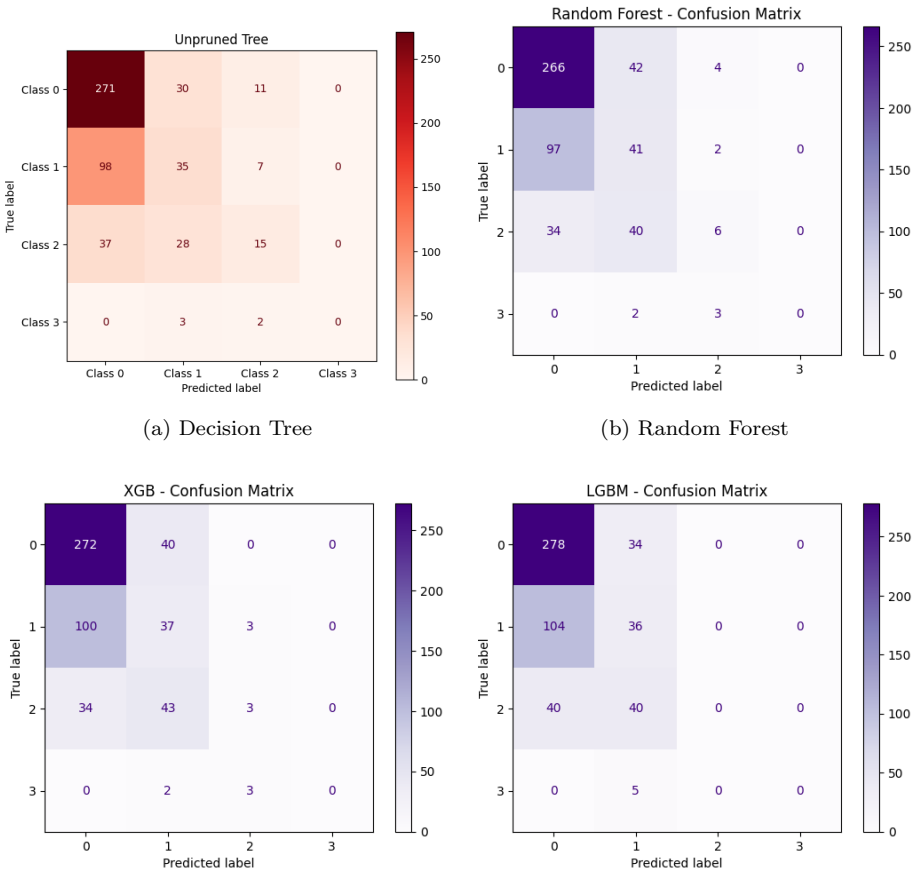
Per ogni modello è stata applicata lo stesso procedimento:

- Addestramento con parametri di default.
- Ottimizzazione dei parametri tramite **GridSearch** o **RandomizedSearch**.
- Valutazione dei modelli ottimizzati in termini di **accuratezza**, **importanza delle feature** e **matrice di confusione**.
- Selezione automatica delle feature tramite **RFECV**.
- Nuovo addestramento con parametri e numero di feature ottimali.
- Uso della **cross-validation** in tutte le fasi per stimare la robustezza del modello ed evitare overfitting.

Per il modello Decision Tree è stata inoltre sperimentata una procedura di **pruning** per ridurre la complessità dell'albero. Tuttavia, i risultati ottenuti sono stati scarsi: la struttura dell'albero e le predizioni non sono cambiate rispetto al modello senza potatura.

4 Valutazione delle prestazioni

La valutazione quantitativa dei modelli è stata effettuata principalmente tramite la metrica di **accuracy**, mentre quella qualitativa si è basata sull'analisi delle **matrici di confusione**, utili per identificare quali classi risultano più o meno predette correttamente. Come si vedrà dalle matrici di confusione riportate sotto, tutti i modelli mostrano un comportamento simile, con la classe 0 largamente sovra-rappresentata nelle predizioni, mentre le classi con minor numero di istanze (in particolare la classe 3) risultano difficili da classificare correttamente.



(a) Decision Tree

(b) Random Forest

(c) XGBoost

(d) LightGBM

Figure 2: Matrici di confusione

Di seguito è riportata l'accuratezza dei modelli ottimizzati con i parametri scelti e il numero di feature ideale:

- **Decision Tree**

  - Accuratezza sul training set: 61.95
  - Accuratezza sul test set: 59.78
  - Accuratezza media con cross-validation: 61.85

- **Random Forest**
  - Accuratezza sul training set: 65.77
  - Accuratezza sul test set: 58.29
  - Accuratezza media con cross-validation: 61.90

- **XGBoost**
  - Accuratezza sul training set: 62.65
  - Accuratezza sul test set: 58.10
  - Accuratezza media con cross-validation: 61.66

- **LightGBM**
  - Accuratezza sul training set: 62.32
  - Accuratezza sul test set: 58.47
  - Accuratezza media con cross-validation: 61.85

5 Analisi dell'importanza delle feature

Per ciascun modello ottimizzato sono state visualizzate le feature con il maggior contributo alla predizione. Successivamente, tramite la tecnica di **Recursive Feature Elimination with Cross-Validation** (RFECV), è stato selezionato il numero ottimale di feature da utilizzare.

Nonostante i modelli abbiano selezionato un numero ottimale di feature molto diverso tra loro, è emersa una certa coerenza nelle variabili ritenute più influenti. In particolare, le seguenti feature sono risultate costantemente tra le più importanti in tutti i modelli:

- **Basic_Demos-Age**
- **Physical-Height**
- **Physical-Weight**
- **SDS-SDS_Total_Raw**
- **PreInt_EduHx-computerinternet_hoursday**